LEX.UZ RAG API · TO‘LIQ QO‘LLANMA

Loyiha boshdan oxirigacha

Nima qiladi, qanday ishlaydi, qaysi fayl nima uchun bor, nima tasdiqlangan va nima tasdiqlanmagan.

MUNDARIJA

1 Loyiha nima qiladi
2 Nima tasdiqlangan, nima yo‘q
3 Ma‘lumot qayerdan keladi
4 Qanday saqlangan
5 Indeks qanday quriladi
6 Savol qanday javob oladi
7 Qidiruv: ikki usul va fusion
8 Tekshiruv darvozasi
9 Provayder qatlami
10 API: 5 endpoint
11 Har bir papka va fayl
12 Topilgan va tuzatilgan xatolar
13 O‘lchangan natijalar
14 Cheklovlar
15 Ishga tushirish va tekshirish
16 Chalg‘itishi mumkin bo‘lgan 3 narsa

01

Loyiha nima qiladi

O‘zbekiston qonunchiligi bo‘yicha savolga javob beradi — lekin o‘zidan o‘ylab topmaydi. Har bir javob aniq moddadan olinadi, va javob bilan birga **isbot** qaytariladi: qaysi kodeks, qaysi modda, qaysi qism, lex.uz havolasi, va moddadan harfma-harf ko‘chirilgan parcha.

Nega bu muhim: oddiy chatbot yuridik savolga ishonchli ovozda xato javob berishi mumkin. Shuning uchun bu loyihadagi asosiy muhandislik ishi javob yozish emas — javobni **tekshiriladigan** qilish.

Topshiriq *RAG API — test spetsifikatsiyasi (lex.uz)* hujjatida: bitta batch endpoint 10 tagacha savolni qabul qilib, har biri uchun javob, manbalar va topilgan kontekstlarni qaytarishi kerak. Maqsad — RAG ning ikki qismini **alohida** baholash: qidiruv to‘g‘ri moddani topdimi, va javob shu moddaga sodiqmi.

02

Nima tasdiqlangan, nima yo‘q

«100% ishlaydi» deb aytib bo‘lmaydi, va aytmaslik kerak. Quyida nima haqiqatan o‘lchangani va nima o‘lchanmagani ajratilgan.

TASDIQLANGAN — REAL ISHGA TUSHIRIB

NIMA	QANDAY TEKSHIRILGAN
HTTP kontrakt (5 endpoint)	77 avtomat test + qo‘lda `curl`
Barcha status kodlari	400 / 401 / 403 / 409 / 429 / 202 / 404 / 503 — har biri test bilan
Qidiruv, 3 tilda	Qo‘lda tasdiqlangan 5 savol: **5/5 birinchi o‘rinda**
100 savollik baholash	10 batch ketma-ket, real HTTP orqali
Groq provayderi	To‘liq, 20 real savol
Idempotentlik, 409, async 202	Test va real run’da
Spec §4 majburiy maydonlar	Real javob qatorma-qator solishtirildi

TASDIQLANMAGAN — VA NEGA

NIMA	HOLAT
Claude (Anthropic) real servisda	So‘rov shakli, structured output va token hisobi soxta `api.anthropic.com` da tasdiqlandi. **Real servisda emas** — mavjud kalit 429 beradi
Gemini generatsiyasi	Kalit va model ro‘yxati ishlaydi; javob yozish emas — o‘sha paytda barcha model `503 high demand` bergan
OpenAI real servisda	Groq bilan **bir xil kod yo‘li** (Groq to‘liq tekshirilgan), plus 4 xil parametrni rad etadigan soxta endpointda sinaldi. Real OpenAI kalitida emas
Pullik kalitda 100 savol	Faqat bepul Groq kalitida o‘lchangan, u yerda kvota cheklaydi
Airflow DAG haqiqatan ishga tushishi	`apache-airflow` bu mashinada o‘rnatilmagan. Papka nomi to‘qnashuvi tuzatildi va kutubxona requirements’ga qo‘shildi, lekin DAG yurgizilmagan
Hit@5 (modda), MRR, answer correctness	Test to‘plamida gold javoblar ataylab bo‘sh — 14-bo‘lim

> QISQA JAVOB
>
> Spec talab qilgan API, qidiruv va sitata mexanizmi — **o‘lchangan va ishlaydi**. Provayder tomoni: Groq to‘liq tekshirilgan, OpenAI bir xil kod yo‘lidan boradi, Claude va Gemini esa real servisda hali sinalmagan — garchi Claude kod yo‘li soxta serverda to‘g‘ri ishlagan bo‘lsa ham.
>
> Qayta tekshirish uchun bitta buyruq bor: `python scripts/verify.py --quick`. Oxirgi yurgizish: **6 o‘tdi, 0 yiqildi**.

03

Ma‘lumot qayerdan keladi

Manba — GitHub’dagi ochiq (CC0) *Uzbek Legal Corpus* to‘plami, asli lex.uz’dan olingan. Ichida **25 hujjat**: Konstitutsiya, 20 kodeks va 4 qonun — jami **7 383 modda**, `2026-07` snapshot.

Har modda bitta JSON obyekt:

```
{"code": "mehnat_kodeksi", "article_id": "217",
 "article_display": "217-modda",
 "title": "Har yilgi asosiy eng kam mehnat ta’tilining davomiyligi",
 "section": "X BO‘LIM.", "chapter": "35-bob...",
 "lex_uz_doc": "-6257288",
 "text": "Har yilgi asosiy eng kam mehnat ta’tilining davomiyligi
          yigirma bir kalendar kunni tashkil etadi."}
```

`manifest.csv` har hujjat uchun lex.uz raqami, qabul sanasi va modda sonini beradi — sitatadagi `doc_id`, `url` va `edition_date` shundan keladi.

Korpus versiyasi **qotirilgan**: commit SHA `data/corpus/CORPUS_SOURCE.md` da yozilgan. Nega — har javobda `index_version` «2026-07 snapshot» deb da‘vo qiladi; agar har kim korpusni yangidan yuklab olsa, indeks jimgina o‘zgarib, ikki run’ning bahosi taqqoslanmay qolardi.

04

Qanday saqlangan

Savol tez-tez beriladi: **Chroma emas, Qdrant.** Va aslida uchta joy bor, har biri boshqa narsa uchun:

JOY	NIMA SAQLANADI	HAJM	NEGA SHU YERDA
`Qdrant · lex_uz`	768 o‘lchamli vektorlar + modda payload’i	7 383	Payload bo‘yicha filtr va to‘liq `scroll` kerak edi
`operativ xotira`	BM25 teskari indeks	7 383	Korpus kichik; alohida qidiruv servisi hech nima qo‘shmaydi
`SQLite`	batch natijalari, 30 kun	—	Idempotentlik, 409 aniqlash, async holat

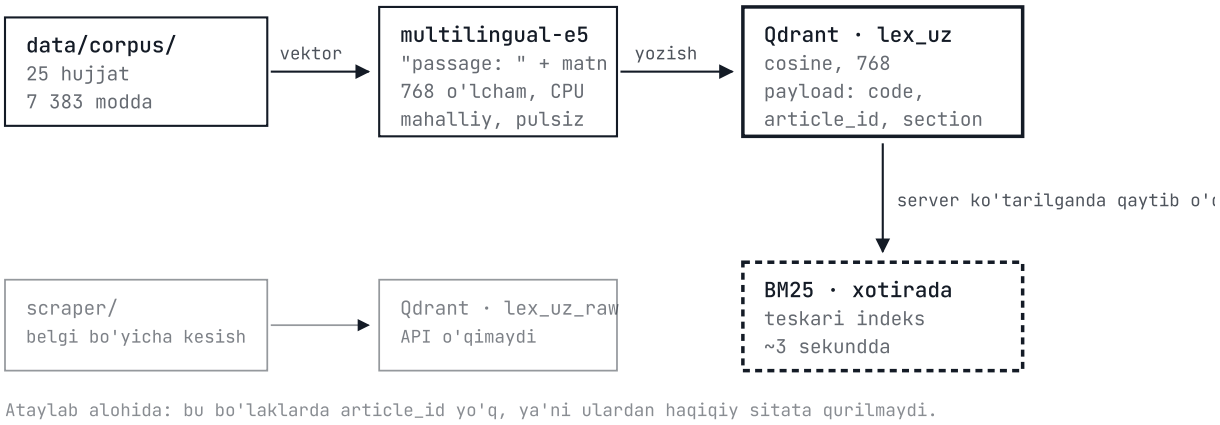
`Qdrant · lex_uz_raw`	skrape qilingan hujjatlar	60	Ajratilgan: modda strukturasi yo‘q, ya’ni haqiqiy sitata bermaydi

Embedding modeli — `multilingual-e5-base` , 768 o‘lcham, **mahalliy, CPU da, API kaliti kerak emas, pul ketmaydi**. Indekslash va qidirish bir xil model va bir xil `passage:` / `query:` prefikslarini ishlatishi shart — aks holda vektorlar taqqoslanmaydi va qidiruv jimgina buziladi. Shuning uchun modelning **bitta uyi** bor: `backend/embedding.py` .

05

Indeks qanday quriladi

Bu bir marta bajariladi. Chunking **modda bo‘yicha**, belgi soni bo‘yicha emas — shu sababli `citations[].article` aniq, taxmin emas.

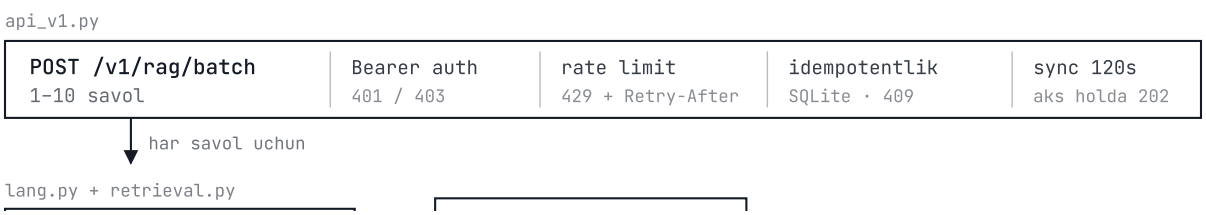


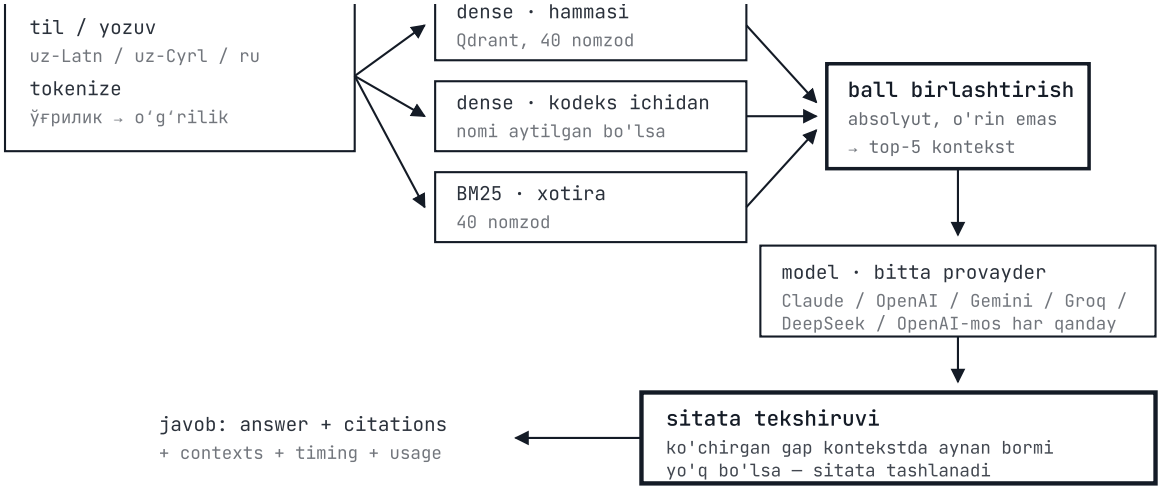
Ataylab alohida: bu bo'laklarda article_id yo'q, ya'ni ulardan haqiqiy sitata qurilmaydi.

Bitta modda = bitta bo‘lak, va shu payload ikki qidiruvni ham to‘ydiradi. Xira yo‘l — kunlik skraper, ataylab boshqa kolleksiyaga yozadi.

06

Savol qanday javob oladi





Har so‘rov qidiruv boshlanmasdan to‘rt darvozadan o‘tadi, keyin har savol uch manbaga tarqalib, birlashtirilgan top-5 ga yig‘iladi. Oxirgi quti javobni ishonchli qiladigan qism.

07

Qidiruv: ikki usul va fusion

Ikki qidiruv har savolda birga ishlaydi, chunki har biri boshqasi uddalamagan joyda ishlaydi.

Dense (vektor) ma‘noni topadi. *«ishdan bo‘shatishsa nima qilish kerak»* deb so‘ralsa, u *«mehnat shartnomasini bekor qilish»* moddalarini topadi — boshqa so‘z, bir xil mavzu.

BM25 (leksik) kam uchraydigan hal qiluvchi atamani topadi. *«o‘g‘irlik»* deb so‘ralsa, sarlavhasi *«O‘g‘rilik»* bo‘lgan moddani darhol topadi.

Nega ball, o‘rin emas

Dastlab standart usul — RRF (reciprocal rank fusion) ishlatilgan edi. Bu korpusda noto‘g‘ri. Yuridik moddalar lug‘atni baham ko‘radi, shuning uchun e5 o‘xshashliklari zichlashadi: bitta savolning 40 nomzodi odatda **0.79–0.81** oralig‘ida. Ya‘ni dense *tartibi* deyarli tasodif. BM25 farqi esa keng va ma‘noli — sarlavhaga aniq moslik **12.5**, keyingisi **7.9**.

RRF ball kattaligini tashlab yuboradi — aynan shu yerda farqlaydigan signalni. *O‘g‘irlik* savolining to‘g‘ri moddasi 5-o‘rinda ko‘milib qolgan edi. Absolyut ball bilan 1-o‘ringa chiqdi:

```
fused = 1.0 · dense + 0.8 · leksik + 0.3 · kodeks bonusi
```

```
fused = 1.0 * dense + 0.6 * leksik + 0.3 * kodeks_bonusi

dense   = clamp((cosine - 0.75) / 0.20, 0, 1)   absolyut, nisbiy emas
leksik  = bm25 / (bm25 + 6)                     to'yinuvchi
kodeks  = 0.3 agar savol shu kodeksni atagan    tekis
```

Har bir had ataylab: `dense` *absolyut* cosine oralig‘ini xaritalaydi, ya‘ni bir-biriga o‘xshash o‘rtamiyona nomzodlar to‘dasi o‘zining eng yaxshisini 1.0 ga ko‘tara olmaydi. `leksik` to‘yinadi, ya‘ni kuchli aniq moslik tasodifiy so‘z ustma-ustligidan ancha ko‘p turadi. Kodeks bonusi *tekis* — bir kodeks ichidagi nomzodlar orasida o‘zaro bekor bo‘ladi.

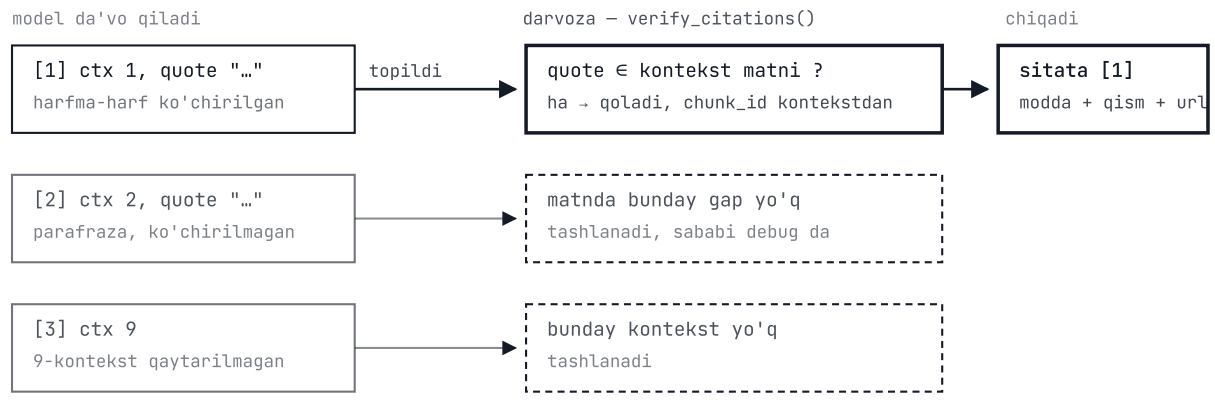
Yana bitta zarur qadam: korpus lotin yozuvida, shuning uchun kirill savol (*ўғрилик*) uni javob beradigan modda bilan (*o‘g‘rilik*) bitta ham umumiy token baham ko‘rmaydi. Tokenizatsiya ichida **kirill → lotin transliteratsiya** bor.

08

Tekshiruv darvozasi

Model matn emas, strukturalangan JSON qaytaradi: javob (ichida `[1]` kabi belgilar), va har bir belgi uchun qaysi kontekstdan olgani plus **harfma-harf ko‘chirgan** parcha.

«So‘raldi» degani «kafolatlandi» degani emas, shuning uchun har bir da‘vo chiqishda qayta tekshiriladi:



Hech qaysi sitata qolmasa, javob o'rniga no_answer qaytariladi — asossiz javob chiqmaydi.
Javob matnidagi [n] belgilari qolgan sitatalarga moslab qayta raqamlanadi.

`chunk_id` kontekstdan o‘qiladi, modeldan hech qachon olinmaydi — shuning uchun tizim ko‘rmagan narsaga havolaning kelib chiqadigan joyi yo‘q.

NIMA BERADI

100 savolda o‘lchangan: faithfulness **1.000**, citation accuracy **0.966**, to‘qilgan manba **0**. Kuchsiz model bu yerda sitatani *yo‘qotadi*, o‘ylab topmaydi — yuridik vositadan aynan shu kutiladi.

09

Provayder qatlami

Faqat **uchta** kod yo‘li bor: ikki native API (Anthropic, Gemini) va qolgan hammasi gaplashadigan OpenAI chat-completions protokoli. Shuning uchun DeepSeek, OpenRouter, Together, Mistral, xAI, Fireworks, Cerebras, Ollama, LM Studio — jadvaldagi bitta qator, kod emas.

`RAG_LLM_BACKEND=auto` bo‘lsa, qaysi kalit mavjud bo‘lsa shu provayder tanlanadi — ya‘ni `.env` ga **istalgan bitta kalit** tashlash butun sozlash. Hech narsa sozlanmasa, offline generatorga tushadi, ya‘ni servis har holda ishga tushadi.

Yana bir nozik joy: qaysi ixtiyoriy parametrni endpoint qabul qilishi *modelga* bog‘liq, provayderga emas — ba‘zilari `temperature` ni rad etadi va `max_tokens` o‘rniga `max_completion_tokens` talab qiladi. Shuning uchun so‘rov foydali narsalarning hammasi bilan boshlanadi va endpoint nimaga e‘tiroz qilsa, o‘shani tashlaydi yoki qayta nomlaydi — har bir moslashuv `debug` da yoziladi.

10

API: 5 endpoint

ENDPOINT	VAZIFASI	SPEC
`POST /v1/rag/batch`	1–10 savol, javob + manba + kontekst	MAJBURIY
`GET /v1/rag/batch/{id}`	Natijani qayta olish, async poll	MAJBURIY
`GET /v1/meta`	Model, embedding, indeks versiyasi, cheklovlar	MAJBURIY
`GET /v1/health`	Servis ishlayaptimi (auth kerak emas)	MAJBURIY
`POST /v1/rag/query`	Bitta savol, debug uchun	ixtiyoriy

Auth: `Authorization: Bearer <API_KEY>`. Test kaliti `RAG_API_KEYS` da, sukut bo‘yicha `test-key-lex-2026`. Javoblar `application/json; charset=utf-8`, va `o‘`, `g‘`, `’` belgilari buzilmaydi.

STATUS KODLARI

KOD	QACHON
200	Batch qayta ishlandi (ba‘zi savollarda xato bo‘lishi mumkin)
202	120s dan oshdi — `GET` bilan olinadi
400	10 dan ko‘p savol, takroriy `id`, bo‘sh savol, 2000+ belgi
401 / 403	Header yo‘q yoki noto‘g‘ri / kalit tanilmadi
404	Bunday `batch_id` yo‘q
409	Shu `batch_id` boshqa savollar bilan yuborilgan
429	Sekundda bittadan tez — `Retry-After` bilan
503	Butun batch yiqildi — tester qayta urinadi

Savol darajasidagi kodlar: `RETRIEVAL_FAILED`, `INDEX_UNAVAILABLE`, `LLM_TIMEOUT`, `LLM_ERROR`, `CONTEXT_TOO_LONG`, `INVALID_LANGUAGE`. Bitta savoldagi xato butun batch‘ni yiqitmaydi: batch `200` qaytaradi, xato esa o‘sha savolning `status` va `error` maydonida ko‘rinadi, kontekstlari esa baribir to‘ldirilgan bo‘ladi — shuning uchun qidiruv xatosini generatsiya xatosidan ajratish mumkin.

11

Har bir papka va fayl

BACKEND/ — API VA RAG MANTIG‘I

`retrieval.py` 584	Ikki qidiruv, tokenizatsiya, kirill→lotin transliteratsiya, kodeks aniqlash, BM25 indeks, ball birlashtirish. Eng katta mantiq shu yerda
`generate.py` 796	Prompt, JSON sxema, uch provayder yo‘li + offline, parametr moslashuvi, javob keshi, chaqiruvlarni me‘yorlash
`pipeline.py` 433	Har savol uchun orkestr, **sitata tekshiruvi**, qayta urinish, `/v1/meta` mazmuni
`api_v1.py` 246	5 endpoint: auth, rate limit, idempotentlik, sync/async
`config.py` 261	Barcha sozlama bir joyda; `Provider` va `resolve()` — qaysi provayder ishlatiladi

`store.py` 178	SQLite: batch saqlash, 409 aniqlash, async holat, 30 kun; rate limiter
`schemas.py` 104	So‘rov validatsiyasi (400 holatlari) va UTF-8 javob klassi
`corpus_meta.py` 97	`manifest.csv` dan hujjat metadata‘si — sitata maydonlari shundan
`main.py` 115	FastAPI yig‘ish, xato konvertlari, startda indeksni isitish
`lang.py` 71	Til/yozuv aniqlash, apostrof normallashtirish
`embedding.py` 48	Umumiy embedding modeli — indekslash va qidirish bir xil bo‘lishi shart

SCRIPTS/ — BAHOLASH VA YORDAMCHILAR

`verify.py` 381	**«Tayyormi?»** — bitta buyruq: muhit, Qdrant, indeks, 3 tilda qidiruv, 77 test, provayder → bitta xulosa
`score_eval.py` 385	Spec §6 metrikalari: Hit@5, MRR, faithfulness, latency, xato ulushi
`build_testset.py` 259	100 savollik to‘plamni spec §6 tarkibi bo‘yicha yig‘adi
`run_eval.py` 231	Spec §1 ssenariysi: 10 batch ketma-ket, retry, async poll, uzilsa davom etish
`list_models.py` 176	Kalit qaysi modellarga kira oladi + bitta savolni real sinash
`build_section_titles.py` 107	Korpus tashlab ketgan bo‘lim nomlarini xom matndan tiklaydi

QOLGAN PAPKALAR

`tests/`	`test_api_v1.py` (805 qator) — spec §7 checklist ning har bir bandi. 77 test
`ingest/`	`ingest_corpus.py` korpusni Qdrant `lex_uz` ga joylaydi (bir marta). `ingest.py` — skrape yo‘li, `lex_uz_raw` ga
`data/corpus/`	7 383 modda + `manifest.csv` + kelib chiqish qaydi
`data/eval/`	`testset_100.csv` — 100 savol, 10 batch, 7 kategoriya
`scraper/ + orchestration/`	lex.uz skraperi va kunlik Airflow ishi. `/v1` ishlatmaydi
`README.md / TESTING.md`	Loyiha tavsifi va tester uchun to‘liq yo‘riqnoma (Linux/macOS/Windows)

12

Topilgan va tuzatilgan xatolar

Hammasi **kodni o‘qib emas, ishga tushirib** topilgan — real o‘lchov, real so‘rov, yoki spec‘ni qayta o‘qib solishtirish natijasida.

> **1. RRF fusion to‘g‘ri moddani ko‘mib tashlagan**
>
> Standart rank fusion bu korpusda ishlamaydi: e5 cosine‘lari 0.79–0.81 oralig‘ida zich, BM25 farqi esa 12.5 vs 7.9. RRF ball kattaligini tashlab, aynan farqlaydigan signalni yo‘qotadi.
>
> **Tuzatish:** absolyut ballga asoslangan fusion. To‘g‘ri modda 5-o‘rindan 1-o‘ringa chiqdi.

> **2. Kirill savollar leksik qidiruvda hech nima topmagan**

> Korpus lotin yozuvida; *ўғрилик* javob beradigan modda bilan bitta ham token baham ko‘rmaydi.
>
> **Tuzatish:** kirill → lotin transliteratsiya. Spec 10 ta kirill/rus savolini talab qiladi.

> **3. Kodeks bonusi dense vaznini ikki baravar oshirgan**
>
> Kodeks aniqlanganda dense vazni jimgina 1.0 dan 1.6 ga chiqardi, va cosine 0.845 bo‘lgan umumiy modda hal qiluvchi so‘z sarlavhasida turgan moddani bosib ketardi.
>
> **Tuzatish:** bonus tekis (0.3) — bir kodeks ichida o‘zaro bekor bo‘ladi.

> **4. Indeksda 60 ta buzuq bo‘lak degenerat sitata bergan**
>
> Eski skraper bo‘laklari modda strukturasiz edi, ulardan `doc_id: "lex:"` , `chunk_id: "lex:#art-"` chiqardi.
>
> **Tuzatish:** `/v1` faqat modda darajasidagi korpusni xizmat qiladi, chiqarilgan son `/v1/meta` da ko‘rinadi; kunlik ish endi alohida kolleksiyaga yozadi.

> **5. QQS savoli noto‘g‘ri «javob yo‘q» bergan**
>
> Qidiruv to‘g‘ri moddani 1-o‘rinda topgan (Soliq kodeksi 258-modda), model esa rad etgan — va to‘g‘ri qilgan. Moddada «soliq stavkasi 12 foiz» deyilgan, «QQS» so‘zi yo‘q; u QQS ekani faqat *QO‘SHILGAN QIYMAT SOLIG‘I* sarlavhasi ostida turganidan bilinadi. Korpus esa bo‘limni `"X BO‘LIM."` deb saqlagan — nomni tashlab ketgan.
>
> **Tuzatish:** xom matndan 24 bo‘lim nomi tiklandi, kontekstga `location` qatori qo‘shildi, `qqs` statut so‘zlariga bog‘landi. Natija: «QQS stavkasi 12 foiz [1]».

> **6. Provayder kvotasi tizimning xatosi deb hisoblangan**
>
> Bepul tarifda `429` oddiy hol, lekin u doimiy `LLM_ERROR` bo‘lib qolardi — ya‘ni bepul kalitdagi tizim pullik kalitdagi aynan shu tizimdan past baho olardi.
>
> **Tuzatish:** 45 sekundlik budjet ichida qayta urinish, `Retry-After` ni hurmat qilib.

> **7. Scorer qisman run‘da maxrajni butun to‘plam deb olgan**
>
> 20 savolga javob kelganda Hit@5 noto‘g‘ri 0.19 chiqqan — «tizim yomon» degan xulosa, aslida «run to‘liq emas».
>
> **Tuzatish:** metrikalar javob kelgan savollar ustidan, qamrov alohida ko‘rsatiladi.

> **8. Airflow papkasi haqiqiy kutubxonani to‘sib qo‘ygan**
>
> `airflow/` nomi sababli `import airflow` bo‘sh papkaga tushardi — DAG hech qachon ishlashi mumkin emas edi, va `apache-airflow` hech qaysi requirements‘da yo‘q edi.
>
> **Tuzatish:** `orchestration/` ga qayta nomlandi, kutubxona requirements‘ga qo‘shildi.

> **9. Spec auditi: `INDEX_UNAVAILABLE` hech qachon chiqmagan**
>
> §5 bu kodni `RETRIEVAL_FAILED` bilan yonma-yon sanaydi — biri «baza bilan aloqa yo‘q», ikkinchisi «shu savolning qidiruvi yiqildi». Kodda har qanday xato ikkinchisi deb qaytarilardi.
>
> **Tuzatish:** ulanish va timeout xatolari alohida tasniflanadi.

> **10. Spec auditi: butun batch yiqilsa HTTP 200 qaytgan**
>
> §5 servis xatosini 500/503/504 ga bog‘lagan, va aynan shu kod testerga qayta urinishni aytadi. 200 bilan `run_eval.py` nol javobli batch‘ni natija deb saqlab o‘tib ketardi.
>
> **Tuzatish:** endi `503` ; `GET` esa saqlangan `failed` yozuvini berishda davom etadi.

Yana to‘rtta kichik, lekin real: provayder model default‘lari eskirgan edi (ikkisi ham sinalgan kalitlarda mavjud emas); Groq‘ning ikki xil JSON xatosidan faqat bittasi ushlangan va ikkinchisi noto‘g‘ri `CONTEXT_TOO_LONG` deb belgilangan; avtomatik aniqlash hech narsa sozlanmaganda Ollama‘ni

tanlagan; va testlar real modelga murojaat qilib 274 sekund ketgan va bepul tarif limiti «test yiqildi» bo‘lib ko‘ringan.

13

O‘lchangan natijalar

100 savol, real HTTP endpoint orqali, 10 batch ketma-ket:

METRIKA	NATIJA	MAQSAD	HOLAT
Hit@5 (hujjat)	0.978	≥ 0.90	O‘TDI
Context precision	0.960	≥ 0.60	O‘TDI
Faithfulness	1.000	≥ 0.95	O‘TDI
Citation accuracy	0.966	≥ 0.90	O‘TDI
To‘qilgan manba	0	0	O‘TDI
Eskirgan norma	0	0	O‘TDI
Latency p50 / p95	0.23s / 0.27s	≤ 5s / ≤ 12s	O‘TDI
Xato ulushi	0.000	≤ 0.02	O‘TDI
Hit@5 (modda), MRR	—	≥ 0.80 / 0.70	GOLD KERAK
Answer correctness	—	o‘rtacha ≥ 1.6	GOLD KERAK

Latency generatsiyani hisobga olmaydi. Provayder ulanganda p50 1–3 sekund oralig‘ida bo‘ladi, maqsad esa 5 sekund.

Uch tilda qo‘lda tekshirilgan 5 savol: **5/5 birinchi o‘rinda**.

RAQAMLAR

Yangi yozilgan kod	~5 250 qator
Hujjat	~1 170 qator
Test	77 o‘tadi, 1 skip
Indekslangan modda	7 383
Hujjat (kodeks + qonun + Konstitutsiya)	25
Test to‘plami	100 savol / 10 batch
Provayder	11 preset + custom
O‘chirilgan o‘lik kod va balast	~700 qator + 15 MB

14

Cheklovlar

Bular `GET /v1/meta` ning `caveats` maydonida ham yozilgan, shuning uchun o‘zgarmas qiymat «ishlayotgan tekshiruv» deb tushunilmaydi.

1. **Hit@5 (modda), MRR, answer correctness o‘lchanmagan.** `expected_article` va `expected_answer` ustunlari ataylab bo‘sh: savol qaysi moddaga tushishi «kerak» ekanini yozish uchun statutlarni o‘qish kerak, va agar ularni tizimning o‘z chiqishidan to‘ldirsam, baholash tizimni o‘zi bilan o‘zini tekshirgan bo‘lardi. Spec ham test to‘plamini tester tomonida deb belgilagan. Shu ikki ustun to‘ldirilsa, scorer uchala metrikani avtomat hisoblaydi.
2. **`doc_status` doim «amalda».** 25 hujjatning hammasi kuchda, ya‘ni «eskirgan norma» metrikasi yiqila olmaydi. U yerdagi `0` tekshiruv ishlayotganining dalili emas.
3. **`edition_date` hujjat bo‘yicha.** Korpus amaldagi konsolidatsiyalangan matnning sanali snapshot‘i, tahrir tarixi yo‘q. Modda darajasidagi sanalar uchun lex.uz revizion skrape kerak.
4. **`as_of_date` qayd qilinadi, lekin xizmat qilinmaydi.** Faqat bitta snapshot indekslangan; oldingi sana `debug` ga ogohlantirish qo‘shadi, noto‘g‘ri tahrirdan javob bermaydi.
5. **`temperature` / `seed` provayderga bog‘liq.** Groq ikkisini ham qabul qiladi, Gemini faqat birinchisini, Anthropic SDK 2.x esa hech birini. Ikkisi ham har doim javobda qaytariladi va javob keshi kalitiga kiradi; qidiruv esa konstruksiya bo‘yicha deterministik.
6. **60 xom bo‘lak chiqarilgan.** Kolleksiyada eski skraper bo‘laklari bor; ulardan majburiy `article` / `part` maydonlarini to‘ldirib bo‘lmaydi, shuning uchun `/v1` ularni xizmat qilmaydi va sonini `/v1/meta` da ko‘rsatadi.

15

Ishga tushirish va tekshirish

```
cp .env.example .env                      # keyin kalit qo'shing
python3 -m venv .venv && source .venv/bin/activate
pip install -r requirements.txt
docker compose up -d                      # Qdrant
python ingest/ingest_corpus.py            # bir marta, 10–25 daqiqa
uvicorn backend.main:app --port 8000      # server
```

Windows da PowerShell: `py -3 -m venv .venv`, `.\.venv\Scripts\Activate.ps1`, va konsolni UTF-8 ga o‘tkazish kerak (aks holda `o‘` ? bo‘lib chiqadi). To‘liq yo‘riqnoma `TESTING.md` da.

TEKSHIRISH

```
python scripts/verify.py --quick          # «tayyormi?» — bitta buyruq
python scripts/run_eval.py --run-id r1    # 100 savol, 10 batch
python scripts/score_eval.py --run-id r1  # §6 metrikalari
python scripts/list_models.py groq --probe # kalitni sinash
```

`verify.py` ketma-ket tekshiradi: muhit, Qdrant, modda indeksi, uch tilda 5 savol, §7 checklist (77 test), va sozlangan provayder — keyin bitta xulosa. `FAIL` bo‘lsa tuzatish yo‘lini ham aytadi. Oxirgi yurgizish: **6 o‘tdi, 0 yiqildi, VERDICT: READY**.

16

Chalg‘itishi mumkin bo‘lgan 3 narsa

Bular to‘g‘ri ishlash, lekin «buzilgan» kabi ko‘rinadi.

Bitta batch 10 savolgacha

20 yoki 30 savolni bitta so‘rovda yuborish `400` qaytaradi: `items: List should have at most 10 items after validation, not 20`. Bu spec §2 talabi. Ko‘proq savol uchun bir nechta batch yuboriladi — baholash ssenariysi aynan shunday: 10 batch × 10 savol.

Sekin batch `202` qaytaradi, `200` emas

Generatsiya 120 sekundlik chegaradan oshsa, javob `{"status": "processing", "poll": "/v1/rag/batch/..."}`

bo‘ladı. Ish yo‘qolmaydı — natıjanı `GET` dan olınadı.

`run_eval.py` buni avtomat qiladi. Bepul Groq kalitida o‘lchangan: 10 savollik batch 285 sekund ketdi va poll talab qildi; pullik kalitda shu batch chegara ichida tugaydi va `200` qaytaradi.

Sekundda bitta batch

Darhol yuborilgan ikkinchi batch `429` va `Retry-After` oladi.

> LLM_ERROR CHIQSA
>
> Deyarli doim provayder kvotasi, loyiha emas. Bepul tarif qattiq: Groq daqiqada 8 000 token beradi, bitta savol ~2 500 token oladi, ya‘ni 10 savol uchun taxminan uch daqiqalik kvota kerak. Yechim: pullik kalit, yoki `RAG_GEN_MIN_INTERVAL_S=20` bilan chaqiruvlarni me‘yorlash.

Hozirgi holat: `main → c57c872` , remote bilan bir xil. `verify.py --quick` → 6 o‘tdi, 0 yiqildi. 77 test o‘tadi. Ikki ochiq shart: baholash uchun pullik provayder kaliti, va test to‘plamidagi ikki gold ustun.