RAG API — test spetsifikatsiyasi (lex.uz)

Nov 3, 2026 · @jurabek

1. Maqsad va test ssenariysi

Jamoa bitta batch endpoint beradi: u 10 tagacha savolni qabul qiladi va har bir savol uchun javob, lex.uz manbalari (hujjat + modda) va topilgan kontekst bo'laklarini qaytaradi. Shu ma'lumot bilan RAG ning ikki qismini alohida baholaymiz: **qidiruv** (to'g'ri qonun va modda topildimi) va **generatsiya** (javob to'g'ri va faqat manbaga asoslanganmi).

Test ssenariysi:

1. Tester 100 ta savoldan iborat test to'plamini tayyorlaydi (savol + kutilgan javob + kutilgan manba). Kutilgan javoblar API ga **yuborilmaydi**.
2. Savollar 10 ta batch ga bo'linadi, har birida 10 ta savol, `q001` – `q100` ID lari bilan.
3. Batch lar ketma-ket yuboriladi: oldingi batch javobi kelgandan keyin keyingisi (`b01` → `b10`).
4. Har bir javob JSON holida saqlanadi (`run_id/b01.json` ...).
5. 10 ta batch tugagach, javoblar test to'plami bilan solishtiriladi va 6-bo'limdagi metrikalar hisoblanadi.
6. Tizim o'zgarganda (yangi model, indeks, chunking) xuddi shu 100 savol qayta yuboriladi va natijalar `run_id` bo'yicha taqqoslanadi.

2. Umumiy talablar

API REST + JSON bo'lishi, `/v1` versiyasi bilan ishlashi va bitta so'rovda 10 tagacha savolni qabul qilishi kerak.

Endpoint	Vazifasi	Majburiy
`POST /v1/rag/batch`	1–10 savolni yuborish, javoblarni olish	Ha
`GET /v1/rag/batch/{batch_id}`	Batch natijasini qayta olish (async rejim yoki qayta tekshirish)	Ha
`POST /v1/rag/query`	Bitta savol (debug uchun)	Yo'q

Endpoint	Vazifasi	Majburiy
`GET /v1/meta`	Model, embedding, indeks versiyasi, lex.uz snapshot sanasi	Ha
`GET /v1/health`	Servis ishlayaptimi	Ha

Texnik talablar:

- **Autentifikatsiya:** `Authorization: Bearer <API_KEY>` header. Test uchun alohida kalit.
- **Kodlash:** `Content-Type: application/json; charset=utf-8`. O‘zbek lotin, o‘zbek kirill va rus tilidagi savollar qabul qilinadi; `o'`, `g'`, `‘` belgilari buzilmasligi kerak.
- **Batch hajmi:** `items` 1–10 ta. 10 dan ko‘p bo‘lsa `400`.
- **Timeout:** bitta batch uchun ⩽ 120 soniya (sync). Uzoqroq bo‘lsa async rejim (5-bo‘lim).
- **Rate limit:** kamida 1 batch/soniya; oshib ketsa `429` + `Retry-After`.
- **Takrorlanuvchanlik:** `temperature = 0`, `seed` qo‘llab-quvvatlanadi. Bir xil savol bir xil indeksda bir xil manbalarni qaytarishi kerak.
- **Idempotentlik:** bir xil `batch_id` qayta yuborilsa, saqlangan natija qaytadi (qayta hisoblanmaydi).
- **Versiyalash:** har bir javobda tizim versiyalari (`system` obyekti) bo‘ladi, aks holda run larni taqqoslab bo‘lmaydi.

3. Request formati (`POST /v1/rag/batch`)

Har bir batch — bitta JSON: run va batch identifikatorlari, umumiy sozlamalar va 10 tagacha savol. Kutilgan javob va kutilgan manba so‘rovga qo‘shilmaydi, ular faqat tester tomonida turadi.

```
{
  "run_id": "eval-2026-11-03",
  "batch_id": "eval-2026-11-03-b01",
  "batch_index": 1,
  "total_batches": 10,
  "options": {
    "top_k": 5,
    "return_contexts": true,
    "return_debug": true,
    "temperature": 0,
```

```
    "seed": 42,
    "as_of_date": "2026-11-01",
    "answer_language": "auto"
  },
  "items": [
    {
      "id": "q001",
      "question": "Yillik asosiy mehnat ta'tilining eng kam muddati qancha?",
      "language": "uz-Latn"
    },
    {
      "id": "q002",
      "question": "Какой срок исковой давности установлен Гражданским
кодексом?",
      "language": "ru"
    }
  ]
}
```

Maydon	Turi	Majburiy	Izoh
`run_id`	string	Ha	Butun 100 savollik test sessiyasi ID si
`batch_id`	string	Ha	Unikal; idempotentlik kaliti
`batch_index` / `total_batches`	int	Ha	1–10 / 10; log va monitoring uchun
`options.top_k`	int	Yo'q (default 5)	Nechta kontekst bo'lagi qaytarilsin
`options.return_contexts`	bool	Yo'q (default true)	Topilgan bo'laklar matni bilan qaytsin
`options.return_debug`	bool	Yo'q	Qayta yozilgan so'rov, rerank ballari, vaqtlar
`options.temperature`, `seed`	number, int	Yo'q	Takrorlanuvchan natija uchun
`options.as_of_date`	date	Yo'q	Qaysi sanadagi amaldagi tahrirga tayanilsin

Maydon	Turi	Majburiy	Izoh
`options.answer_language`	string	Yo'q	`auto` = savol tilida; `uz-Latn`, `uz-Cyrl`, `ru`
`items[].id`	string	Ha	Batch ichida unikal (`q001` – `q100`)
`items[].question`	string	Ha	1–2000 belgi
`items[].language`	string	Yo'q	Ko'rsatilmasa avtomatik aniqlanadi

Batch lar ketma-ket yuboriladi: `b01` javobi kelgach `b02`, va hokazo. Javob kelmasa yoki `retryable: true` xato bo'lsa, o'sha `batch_id` bilan qayta yuboriladi.

4. Response formati

Har bir savol uchun javob matnining o'zi yetarli emas: RAG ni tekshirish uchun **manbalar (citations)** va **topilgan kontekstlar (contexts)** ham kerak. Usiz qidiruv xatosini generatsiya xatosidan ajratib bo'lmaydi.

```
{
  "run_id": "eval-2026-11-03",
  "batch_id": "eval-2026-11-03-b01",
  "status": "completed",
  "system": {
    "pipeline_version": "0.4.2",
    "llm_model": "<model nomi>",
    "embedding_model": "<embedding nomi>",
    "reranker": "<reranker nomi yoki null>",
    "index_version": "lex-idx-2026-10-28",
    "lex_snapshot_date": "2026-10-28"
  },
  "timing": {
    "received_at": "2026-11-03T10:30:00+05:00",
    "completed_at": "2026-11-03T10:30:41+05:00",
    "total_ms": 41230
  },
  "summary": { "total": 10, "ok": 9, "no_answer": 1, "error": 0 },
  "results": [
    {
```

```
      "id": "q001",
      "status": "ok",
      "answer": "Yillik asosiy mehnat ta'tili ... kalendar kunidan kam
bo'lmasligi kerak [1].",
      "answer_language": "uz-Latn",
      "no_answer": false,
      "confidence": 0.82,
      "citations": [
        {
          "ref": 1,
          "doc_id": "lex:XXXXXXX",
          "doc_title": "O'zbekiston Respublikasining Mehnat kodeksi",
          "doc_type": "kodeks",
          "url": "https://lex.uz/docs/XXXXXXX",
          "article": "XXX-modda",
          "part": "1-qism",
          "edition_date": "YYYY-MM-DD",
          "doc_status": "amalda",
          "chunk_id": "lex:XXXXXXX#art-XXX#p1",
          "quote": "<manbadan aynan olingan matn bo'lagi>"
        }
      ],
      "contexts": [
        {
          "rank": 1,
          "chunk_id": "lex:XXXXXXX#art-XXX#p1",
          "doc_id": "lex:XXXXXXX",
          "article": "XXX-modda",
          "text": "<to'liq chunk matni>",
          "retrieval_score": 0.78,
          "rerank_score": 0.91,
          "used_in_answer": true
        }
      ],
      "debug": {
        "rewritten_query": "<qayta yozilgan so'rov>",
        "retrieved_total": 50
      },
      "timing": { "retrieval_ms": 320, "rerank_ms": 140, "generation_ms":
2900, "total_ms": 3410 },
      "usage": { "input_tokens": 3120, "output_tokens": 210 },
```

```
      "error": null
    }
  ]
}
```

Maydon	Majburiy	Nega kerak
`results[].id`	Ha	Savolni test to'plami bilan bog'lash; tartib emas, ID bo'yicha solishtiriladi
`results[].status`	Ha	`ok`, `no_answer`, `error`, `timeout`
`answer`	Ha	Javob; ichida `[1]` kabi havolalar `citations[].ref` ga mos
`no_answer`	Ha	Qonunda javob yo'q bo'lsa tizim to'qib chiqarmasdan `true` qaytarishi kerak
`citations[].doc_id`, `url`	Ha	lex.uz hujjati to'g'ri topilganini tekshirish
`citations[].article`, `part`	Ha	Modda / qism darajasida aniqlik
`citations[].edition_date`, `doc_status`	Ha	Kuchini yo'qotgan yoki eski tahrirga tayanmaganini tekshirish
`citations[].quote`	Ha	Javob manbaga asoslanganini (faithfulness) tekshirish
`contexts[]`	Ha	Retrieval metrikalari: Hit@k, Recall@k, MRR
`contexts[].retrieval_score`, `rerank_score`	Ha	Reranker foyda beryaptimi, chegarani tahlil qilish
`confidence`	Yo'q	Ishonch va to'g'rilik bog'liqligini (kalibrovka) ko'rish
`debug`, `usage`	Yo'q	Xatolarni tahlil qilish, narxni baholash
`timing`	Ha	Latency p50 / p95
`system`	Ha	Run larni versiya bo'yicha taqqoslash

Qoidalar:

- `results` dagi elementlar soni `items` soniga teng; har bir `id` bitta marta.
- Har bir `citations[].chunk_id` `contexts` ichida bo'lishi kerak: tizim ko'rmagan manbaga havola bermaydi.
- `doc_id` lex.uz dagi hujjat raqamiga barqaror bog'langan bo'ladi (indeks qayta qurilganda o'zgarmaydi).

5. Xatoliklar, statuslar va rejimlar

Bitta savoldagi xato butun batch ni yiqitmasligi kerak: batch `200` qaytaradi, xato esa o'sha savolning `status` va `error` maydonida ko'rinadi.

HTTP kod	Qachon	Tester nima qiladi
`200`	Batch qayta ishlandi (ba'zi savollarda xato bo'lishi mumkin)	Natijani saqlaydi
`202`	Async rejim: batch qabul qilindi	`GET /v1/rag/batch/{batch_id}` ni poll qiladi
`400`	Validatsiya: 10 dan ko'p savol, takroriy `id`, bo'sh `question`	So'rovni tuzatadi
`401` / `403`	API kalit noto'g'ri	Kalitni tekshiradi
`409`	Shu `batch_id` boshqa mazmun bilan yuborilgan	Yangi `batch_id`
`429`	Rate limit	`Retry-After` dan keyin qayta
`500` / `503` / `504`	Servis xatosi yoki timeout	3 martagacha qayta (5 s, 15 s, 45 s)

Savol darajasidagi xato obyekti:

```
{
  "id": "q007",
  "status": "error",
  "answer": null,
  "citations": [],
  "contexts": [],
  "error": {
    "code": "LLM_TIMEOUT",
    "message": "Generation exceeded 60s",
    "retryable": true
  }
}
```

Tavsiya etilgan xato kodlari: `RETRIEVAL_FAILED`, `INDEX_UNAVAILABLE`, `LLM_TIMEOUT`, `LLM_ERROR`, `CONTEXT_TOO_LONG`, `INVALID_LANGUAGE`.

Sync va async. Asosiy rejim — sync: javob shu so'rovda qaytadi. Batch 120 soniyadan oshsa, server `202` va `{"batch_id": "…", "status": "processing"}` qaytaradi; `GET` keyinchalik `processing` → `completed` / `failed` holatini va 4-bo'limdagi to'liq javobni beradi. Natija kamida 30 kun saqlanadi.

6. RAG ni baholash

Natija ikki qatlamda baholanadi: qidiruv to'g'ri modda topdimi va javob shu moddaga sodiq va to'g'rimi. Quyidagi chegaralar — birinchi run uchun taklif, jamoa bilan kelishiladi.

Test to'plami formati (tester tomonida)

```
id,batch,category,question,expected_answer,expected_doc_id,expected_article,a
nswerable
q001,b01,faktik,"Yillik asosiy mehnat ta'tilining eng kam muddati qancha?","
<kutilgan javob>",lex:XXXXXXX,XXX-modda,true
q010,b01,javobsiz,"<qonunda javobi yo'q savol>",,,,false
```

100 savol tarkibi

Kategoriya	Soni	Nimani tekshiradi
Faktik, bitta modda	35	Asosiy retrieval aniqligi

Kategoriya	Soni	Nimani tekshiradi
Raqamlar: muddat, summa, foiz, BHM	15	Raqamlarni xatosiz ko'chirish
Bir nechta modda / hujjat	15	Ko'p manbani birlashtirish
O'zgargan yoki kuchini yo'qotgan normalar	10	Amaldagi tahrirni tanlash
Rus tili va kirill yozuvidagi savollar	10	Ko'p tillilik
Javobi yo'q / qonundan tashqari	10	`no_answer`, gallyutsinatsiya qilmaslik
Noaniq yoki og'zaki ifodalangan	5	Query rewriting

Har bir batch ga har kategoriyadan aralashtirib qo'yiladi, shunda bitta batch ning o'zi ham kichik namuna bo'ladi.

Metrikalar

Qatlam	Metrika	Qanday hisoblanadi	Maqsad (taklif)
Retrieval	Hit@5 (hujjat)	`expected_doc_id` top-5 `contexts` ichida bormi	⩾ 90%
Retrieval	Hit@5 (modda)	`expected_article` top-5 ichida bormi	⩾ 80%
Retrieval	MRR	To'g'ri moddaning birinchi o'rni bo'yicha	⩾ 0.70
Retrieval	Context precision	Top-5 dan nechtasi savolga tegishli	⩾ 60%
Generatsiya	Answer correctness	Kutilgan javob bilan solishtirish: 0 / 1 / 2 ball (qo'lda yoki LLM-hakam)	o'rtacha ⩾ 1.6
Generatsiya	Faithfulness	Javobdagi har bir da'vo `contexts` da bormi	⩾ 95%
Manba	Citation accuracy	Keltirilgan modda haqiqatan da'voni tasdiqlaydimi	⩾ 90%
Manba	To'qilgan manba	`contexts` da yo'q yoki lex.uz da yo'q havola	0 ta
Manba	Eskirgan norma	Kuchini yo'qotgan hujjatga tayanish	0 ta

Qatlam	Metrika	Qanday hisoblanadi	Maqsad (taklif)
Xavfsizlik	No-answer aniqligi	10 ta javobsiz savoldan nechtasida `no_answer: true`	⩾ 9 / 10
Operatsion	Latency	Savol bo'yicha `total_ms`: p50 / p95	⩽ 5 s / ⩽ 12 s
Operatsion	Xato ulushi	`status = error` yoki `timeout`	⩽ 2%

MRR formulasi (N = javobi bor savollar soni, rank_i = to'g'ri moddaning o'rni):

```
\mathrm{MRR} = \frac{1}{N} \sum_{i=1}^{N} \frac{1}{\mathrm{rank}_i}
```

Xatolarni tahlil qilishda har bir noto'g'ri javob bitta sababga yoziladi: **retrieval** (to'g'ri modda topilmagan), **generatsiya** (modda topilgan, lekin javob noto'g'ri) yoki **manba** (javob to'g'ri, havola noto'g'ri). Bu jamoaga nimani tuzatishni ko'rsatadi.

7. Ishlab chiquvchilar uchun checklist

API testga tayyor deb hisoblanishi uchun quyidagilarning barchasi bajarilgan bo'lishi kerak.

- [ ] `POST /v1/rag/batch` 1–10 savolni qabul qiladi, 11 ta bo'lsa `400`
- [ ] Javobda har bir `id` bitta marta, savollar soniga teng
- [ ] Har bir javobda `citations`: lex.uz `doc_id`, `url`, `article`, `edition_date`, `doc_status`, `quote`
- [ ] Har bir javobda `contexts` (top-k, matni va ballari bilan)
- [ ] Har bir `citations[].chunk_id` `contexts` ichida bor
- [ ] Javobsiz savolga `no_answer: true`, to'qilgan javob yo'q
- [ ] Bitta savoldagi xato boshqalarga ta'sir qilmaydi (`status: error` + `error` obyekti)
- [ ] `system` obyekti: model, embedding, indeks versiyasi, lex.uz snapshot sanasi
- [ ] `temperature = 0` va `seed` bilan bir xil savol bir xil manbalarni qaytaradi
- [ ] Bir xil `batch_id` qayta yuborilsa saqlangan natija qaytadi
- [ ] Lotin, kirill va rus tilidagi savollar to'g'ri ishlaydi, `o'` / `g'` buzilmaydi
- [ ] Batch ⩽ 120 s yoki async `202` + `GET` ishlaydi
- [ ] `GET /v1/meta` va `GET /v1/health` ishlaydi
- [ ] Test uchun alohida API kalit va base URL berilgan

Ochiq savollar jamoa uchun:

- lex.uz dan maʼlumot qaysi sanada olingan va qanchalik tez-tez yangilanadi?
- Chunking modda boʻyichami yoki belgilangan uzunlik boʻyichami? Bu `article` maydonining aniqligiga taʼsir qiladi.
- Kuchini yoʻqotgan hujjatlar indeksda saqlanadimi va qanday belgilanadi?